

Rapport e-handelsanalys

Gruppuppgift - R-programmering för dataanalys

Daniel Riera Carrillo, Isabel Holm, Jan Rajt, Marziyeh Akbari, Simon Stajduhar

Introduktion

I denna rapport analyserar vi orderdata från ett e-handelsföretag som säljer produkter inom flera kategorier till kunder i olika regioner. Analysen utgår från tre frågeställningar:

1. Vilka produktkategorier driver högst försäljning?
2. Finns det ett samband mellan rabatt och ordervärde?
3. Finns det ett samband mellan rabatt och returfrekvens?

Fokus ligger på relationen mellan rabatter, ordervärde och returer. Rabatter är ett vanligt verktyg för att driva försäljning men samtidigt kan påverka lönsamhet och returnmönster.

Rapporten inleds med en beskrivning av data och de förberedelser som gjorts innan analys. Därefter presenteras resultat och visualiseringar för respektive frågeställning, följt av en sammanfattande diskussion av de viktigaste insikterna.

Metod

Datainläsning och initial förståelse

Datasetet lästes in med `read_csv()` från paketet `tidyverse` och innehåller 1 000 observationer fördelade på 16 variabler. En initial granskning genomfördes med `glimpse()` och `head()` för att bilda en uppfattning om variabelernas struktur och datatyper.

Saknade värden

Saknade värden identifierades för fem kolumner: `city`, `payment_method`, `campaign_source`, `discount_pct` och `shipping_days`. Av de variabler som är relevanta för denna analys förekommer saknade värden i `discount_pct`, där 27 observationer (2,7 %) saknar värde.

Table 1: Saknade värden

Kolumn	Antal	Andel
order_id	0	0.0
order_date	0	0.0
customer_id	0	0.0
customer_segment	0	0.0
customer_type	0	0.0
region	0	0.0
city	21	2.1
product_category	0	0.0
product_subcategory	0	0.0
payment_method	25	2.5
campaign_source	31	3.1
quantity	0	0.0
unit_price	0	0.0
discount_pct	27	2.7
shipping_days	22	2.2
returned	0	0.0

Dataförberedelser

Innan analys genomfördes ett antal förberedande steg för att säkerställa datkvaliteten. Samtliga kolumnnamn gjordes enhetliga med gemener, och textvärden rensades från inledande och avslutande mellanslag samt konverterades till gemener. Specialtecken i stadnamn normaliserades, och ett antal stavningsvarianter i **city** och **campaign_source** harmoniserades till enhetliga värden.

Datasetet täcker orderdata från 2025-01-01 till 2025-12-31.

Observationer med saknade värden i **discount_pct** exkluderades från datasetet (27 observationer, 2,7 %). Saknade värden i övriga kolumner hanterades enligt följande: **payment_method**, **city** och **campaign_source** fylldes med kategorin **unknown**, medan saknade värden i **shipping_days** ersattes med medianvärdet.

Kolumnerna **product_category** och **product_subcategory** konverterades till faktorer inför analysen.

Avslutningsvis skapades tre nya variabler inför analysen:

- **order_value** - ordervärde beräknat som kvantitet $\times$ styckpris $\times$ (1 - rabatt)
- **returned_flag** - en binär variabel där 1 indikerar en returnerad order

- `discount_group` - rabatt grupperad i intervall om 5 procentenheter (0–40 %)

Resultat

Vilka produktkategorier driver högst försäljning?

Total försäljning

Total försäljning i perioden: 305395

Produktkategorier som driver högst försäljning




Table 2: Total försäljning per produktkategori

Kategori	Total försäljning	Genomsnittligt ordervärde	Antal ordrar
electronics	150947	645	234
home	58479	287	204
sports	53625	348	154
fashion	31228	136	229
beauty	11116	73	152

Analysen visar total försäljning, genomsnittligt ordervärde och antal ordrar per produktkategori. Där total försäljning för samtliga produktkategorier i perioden uppgår till 305 395 kr. Electronics är den klart dominerande kategorin med en total försäljning på 150 947 kr och ett genomsnittligt ordervärde på 645 kr per order. Home och Sports följer därefter, medan Fashion och Beauty står för betydligt lägre försäljningsvärden trots att Fashion har näst flest antal ordrar (229 st). Detta tyder på att Fashion präglas av låga ordervärden snarare än låg efterfrågan.

Finns det ett samband mellan rabatt och ordervärde?

Översikt ordervärde

Table 3: Ordervärde i kr

Mean	Median	Min	Max
314	151	7	2926

Ordervärdet i datasetet varierar kraftigt, med ett medelvärde på 314 kr och ett medianvärde på 151 kr, vilket tyder på en högersnedfördelning med ett antal höga ordervärden som drar upp medelvärdet. Det lägsta ordervärdet är 7 kr och det högsta 2 926 kr.

Översikt rabatt

Table 4: Översikt rabatter


Mått	Värde
Andel ordrar med rabatt (%)	90.1
Minsta rabatt	0.1%
Högsta rabatt	30.6%
Genomsnittlig rabatt	7.8%

Hela 90,1 % av orderarna innehåller någon form av rabatt, med en genomsnittlig rabatt på 7,8 % och ett max på 30,6 %.

Samband mellan rabatt och ordervärde

Samband mellan rabatt och ordervärde

Varje punkt är en order




Spridningsdiagrammet visar inget tydligt samband mellan rabatt och ordervärde. Trendlinjen är svagt negativ, men lutningen är minimal och spridningen stor, vilket tyder på att rabattens storlek inte har någon nämnvärd påverkan på ordervärdet.

Finns det ett samband mellan rabatt och returfrekvens?

Andel returer

Andel returer i perioden (%): 14.08


Returgrad per rabattnivå



Den totala returgraden i datasetet är 14,08 %. Grafen visar ett tydligt mönster där returgraden ökar med rabattnivån. Vid de lägsta rabattintervallen (0-10 %) ligger returgraden på runt 12 %, för att sedan stiga markant vid högre rabattnivåer. Vid rabatter mellan 20-25 % är returgraden uppe i 25 %, alltså drygt dubbelt så hög jämfört med de lägsta intervallen.

Rabattprocent efter returstatus

Fördelning av rabattprocent för returnerade respektive icke returnerade



Returnerade ordrar har en genomsnittlig rabatt på 8,1 % jämfört med 6,9 % för icke-returnerade ordrar. Ett t-testet visar att denna skillnad är statistiskt signifikant ($p = 0,021$), vilket innebär att det är osannolikt att skillnaden beror på slumpen.

Skillnaden är dock liten, cirka 1,2 procentenheter, och boxploten visar att fördelningarna överlappar stort. Resultatet tyder alltså på ett svagt men statistiskt påvisbart samband mellan högre rabatt och returnerade ordrar, snarare än ett starkt eller avgörande samband.

Det bör noteras att de högre rabattintervallen representerar färre ordrar, vilket syns i den mindre punktstorleken. Sambandet är ändå tydligt nog för att tyda på att högre rabatter hänger ihop med en högre benägenhet att returnera ordern.

Slutsatser

Analysen visar att Electronics är den dominerande produktkategorin och står för den klart högsta försäljningen, trots att Fashion har näst flest antal ordrar. Detta tyder på stora skillnader i ordervärde mellan kategorier.

Gällande sambandet mellan rabatt och ordervärde finner vi inget tydligt mönster. Trendlinjen är svagt negativ men spridningen är stor, vilket tyder på att rabattnivån inte är en avgörande faktor för hur mycket en kund spenderar per order.

Däremot finns ett tydligare samband mellan rabatt och retur. Returgraden ökar markant med rabattnivån, från omkring 12 % vid låga rabatter till 25 % vid de högsta rabattintervallen.

Detta är en relevant insikt för företaget, då höga rabatter riskerar att attrahera ordrar med högre returbenägenhet.

Begränsningar

Datasetet omfattar 1 000 ordrar från ett enskilt år, vilket begränsar möjligheten att dra generella slutsatser. Sambandet mellan rabatt och returer samvarierar men kan inte tolkas som orsakssamband. Dessutom saknas information om exempelvis returorsak, vilket hade kunnat ge en djupare förståelse för returmönstren.